

PREDIKSI HARGA PENUTUPAN SAHAM BANK RAKYAT INDONESIA (BBRI) DENGAN MULTI-LAYER PERCEPTRON

Habiburrohman

Fakultas Matematika dan Ilmu Pengetahuan Alam, Institut Teknologi Bandung

Email: 10121089@mahasiswa.itb.ac.id

Abstrak

1. PENDAHULUAN

PT Bank Rakyat Indonesia (Persero) Tbk atau biasa disingkat BRI, merupakan badan usaha milik negara Indonesia yang menyediakan berbagai jenis jasa keuangan. Salah satu layanan yang ditawarkan oleh BRI yakni investasi berupa saham BBRI. Ruang lingkup kegiatan BBRI yaitu melakukan usaha pada bidang perbankan serta optimalisasi pemanfaatan sumber daya yang dimiliki BRI untuk menghasilkan jasa bermutu tinggi dan berdaya saing kuat guna meningkatkan nilai perusahaan dengan menerapkan prinsip Perseroan Terbatas.

Pada tanggal 31 Oktober 2003, BBRI memperoleh pernyataan efektif dari Bapepam-LK untuk melakukan Penawaran Umum Perdana (*Initial Public Offering / IPO*) Saham BBRI kepada masyarakat sebanyak 3.811.765.000 (30%) saham dengan nilai nominal dan harga penawaran berturut-turut Rp500 dan Rp875 per lembar saham. Selanjutnya, saham ini dicatatkan pada Bursa Efek Indonesia (BEI) pada tanggal 10 November 2003. Pada tanggal 6 Maret 2024, harga penutupan saham BBRI mencapai Rp6.200 dengan kapitalisasi pasar sebesar 920,27 triliun rupiah.

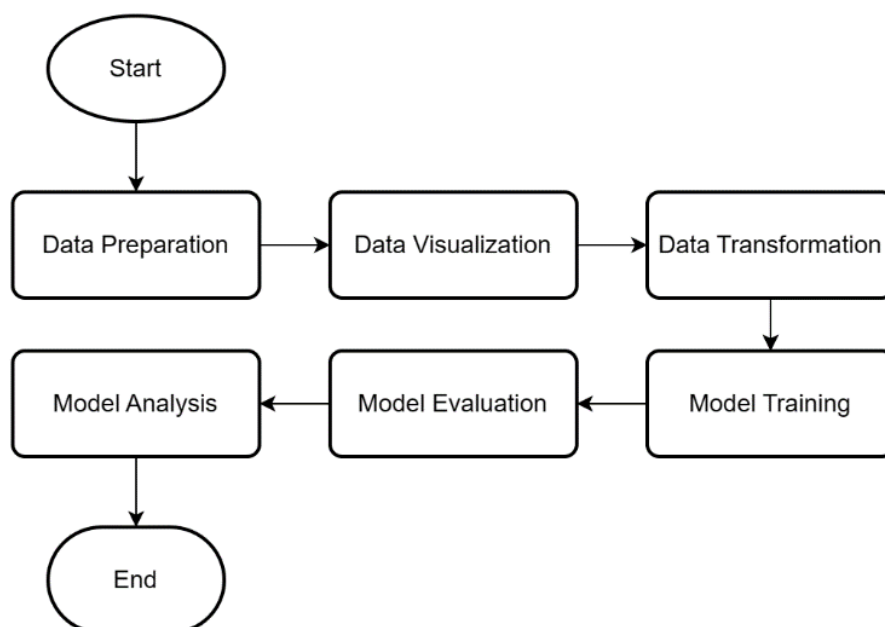
Pembelajaran mendalam (*deep learning*) merupakan bagian dari pembelajaran mesin (*machine learning*) yang menggunakan aringan saraf tiruan (*artificial neural network*). Metode ini bekerja dengan meniru cara kerja otak manusia dalam memproses informasi. Secara umum, lapisan pada jaringan saraf tiruan dibagi menjadi tiga, yakni lapisan masukan (*input layer*), lapisan tersembunyi (*hidden layer*), dan lapisan keluaran (*output layer*). Pada setiap lapisan,

terdapat beberapa *node* yang merepresentasikan satu neuron atau sel saraf manusia. Berdasarkan arah aliran informasi antar lapisannya, jaringan saraf tiruan dibagi menjadi *Feedforward Neural Network* (FNN) dan *Recurrent Neural Network* (RNN). Pada FNN, informasi hanya mengalir satu arah dari *input layer* menuju *output layer*. Sementara itu, pada RNN informasi dapat mengalir dua arah sehingga keluaran dari suatu *node* dapat mempengaruhi masukan berikutnya pada *node* yang sama. FNN dinamakan Multi-Layer Perceptron (MLP) jika memiliki *hidden layer* dan disebut *Single Layer Perceptron* (SLP) jika tidak memiliki *hidden layer*. MLP dikenal mampu membedakan data yang tidak dapat dipisahkan secara linear.

Saat ini, saham merupakan aset berharga dalam dunia investasi. Oleh karena itu, pengetahuan mengenai dinamika harga saham menjadi hal yang penting untuk memproyeksikan keuntungan investasi pada masa yang akan datang. MLP dapat digunakan untuk memodelkan ataupun memprediksi harga saham. Pada bagian selanjutnya, akan dibahas penerapan MLP untuk memodelkan dan memprediksi harga saham BBRI.

2. METODE PENELITIAN

Bahasa pemrograman yang digunakan pada penelitian ini yaitu Python. Tahapan penelitian yang akan dilakukan dapat dilihat pada diagram alir berikut.



Pertama, dilakukan persiapan data dengan mengunduh data berekstensi CSV melalui laman resmi BRI. Data yang sudah diunduh kemudian dibaca dan divisualisasikan. Setelah itu, dilakukan transformasi data berupa penskalaan dengan teknik normalisasi. Kemudian, data akan dibagi menjadi dua, yakni data latih dan data uji. Data latih digunakan untuk melatih model, sedangkan data uji digunakan untuk menguji performa model yang telah dilatih. Selanjutnya, dilakukan pelatihan model MLP dengan nilai parameter tertentu. Setelah dilatih, model akan dievaluasi dengan *loss function* berupa *Mean Squared Error* (MSE) yang dihitung baik pada data latih maupun pada data uji. Terakhir, akan dilakukan analisis performa model yang telah dibuat.

3. HASIL DAN PEMBAHASAN

3.1 Deskripsi Data


Data yang digunakan pada penelitian ini yakni data histori harga saham BBRI dari tanggal 1 Maret 2023 hingga 6 Maret 2024. Data ini memiliki 239 baris dan tujuh fitur dengan rincian sebagai berikut.

Tabel 3.1.1 Deskripsi Data

No.	Fitur	Deskripsi
1	Date	Tanggal
2	Open	Harga pembukaan saham, yakni saat bursa buka pada hari terkait
3	High	Harga tertinggi pada hari terkait
4	Low	Harga terendah pada hari terkait
5	Close	Harga penutupan saham, yakni saat bursa tutup pada hari terkait
6	Volume	Jumlah lembar saham yang diperdagangkan pada hari terkait
7	AdjustedClose	Harga penutupan saham setelah disesuaikan terhadap aksi korporasi, seperti pembagian dividen


3.2 Visualisasi Data

Setiap fitur pada data akan divisualisasikan untuk mengetahui karakteristiknya. Berikut ini adalah grafik perbandingan fitur ‘High’ dan ‘Low’.



Gambar 3.2.1 Harga Tertinggi dan Terendah Harian Saham BBRI Satu Tahun Terakhir

Selanjutnya, berikut ini adalah grafik perbandingan fitur ‘Open’ dan ‘Close’.



Gambar 3.2.2 Harga Pembukaan dan Penutupan Harian Saham BBRI Satu Tahun Terakhir


Adapun perbandingan antara fitur ‘Close’ dan ‘Adjusted Close’ dapat dilihat pada grafik berikut.



Gambar 3.2.3 Harga Penutupan dan Penutupan yang Disesuaikan Saham BBRI Satu Tahun Terakhir

Dari grafik di atas, dapat dilihat bahwa harga penutupan yang disesuaikan persis sama dengan harga penutupan saham BBRI yang merupakan variabel respon atau target pada penelitian ini. Oleh karena itu, nantinya fitur 'AdjustedClose' tidak dijadikan sebagai variabel prediktor.

Selanjutnya, fitur 'Volume' divisualisasikan pada grafik berikut.



Gambar 3.2.4 Volume Perdagangan Harian Saham BBRI Satu Tahun Terakhir

Dari grafik di atas, terlihat bahwa volume perdagangan saham BBRI berfluktuasi setiap harinya, tetapi dengan rata-rata yang relatif stabil.

3.3 Transformasi Data

Sebelum melatih model, data akan ditransformasi dengan teknik normalisasi. Normalisasi merupakan teknik penskalaan data sehingga nilainya berkisar dari nol hingga satu. Hal ini dilakukan karena terdapat fitur yang rentang nilainya jauh berbeda dibandingkan yang lain, seperti fitur ‘Volume’. Perbedaan skala ini dapat mengakibatkan terjadinya bias pada model karena suatu fitur dianggap lebih penting daripada fitur lain. Oleh karena itu, normalisasi perlu dilakukan agar setiap fitur memiliki skala yang sama sehingga proses pelatihan akan berjalan lebih baik. Adapun formula untuk normalisasi adalah sebagai berikut.

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$$

	Date	Open	High	Low	Close	Volume	AdjustedClose
0	20230306	4790.0	4800.0	4780.0	4790.0	78880100	4790.0
1	20230307	4770.0	4850.0	4770.0	4840.0	98412500	4840.0
2	20230308	4850.0	4850.0	4820.0	4840.0	103767800	4840.0
3	20230309	4860.0	4870.0	4810.0	4810.0	79549800	4810.0
4	20230310	4820.0	4830.0	4800.0	4820.0	125157100	4820.0

Gambar 3.3.1 Sampel Data Sebelum Normalisasi

	Date	Open	High	Low	Close	Volume	AdjustedClose
0	0.0000	0.055385	0.030769	0.088328	0.05625	0.088885	0.05625
1	0.0001	0.043077	0.061538	0.082019	0.08750	0.130465	0.08750
2	0.0002	0.092308	0.061538	0.113565	0.08750	0.141866	0.08750
3	0.0003	0.098462	0.073846	0.107256	0.06875	0.090310	0.06875
4	0.0004	0.073846	0.049231	0.100946	0.07500	0.187399	0.07500

Gambar 3.3.2 Sampel Data Setelah Normalisasi

Teknik normalisasi ini akan mengubah nilai data. Oleh karena itu, pada akhir proses pelatihan dan evaluasi model, data akan dikembalikan seperti semula dengan menerapkan formula berikut.

$$X = X' (X'_{max} - X'_{min}) + X'_{min}$$

3.4 Pelatihan Model

Data yang sudah ditransformasi akan dibagi menjadi data latih (*train*) dan data uji (*test*). Pada penelitian ini, digunakan rasio 3:1. Artinya, 75% baris data akan menjadi data latih dan

25% baris data sisanya akan menjadi data uji. Fitur yang dipilih menjadi variabel prediktor adalah ‘Open’, ‘High’, ‘Low’, dan ‘Volume’. Adapun fitur yang menjadi variabel respon atau target untuk diprediksi adalah ‘Close’.

```
# Define predictor and response variables
df_x = df_n[["Open", "High", "Low", "Volume"]]
df_y = df_n["Close"]
X = np.array(df_x)
y = np.array(df_y).reshape(df_y.shape[0], 1)
print(f'Input shape: {X.shape}, Output shape: {y.shape}')

# Train test split
X_train, X_test, y_train, y_test = train_test_splitting(X, y, train_fraction=0.75)

Input shape: (239, 4), Output shape: (239, 1)
Train size: 179 rows (75.0%), Test size: 60 rows (25.0%)
```


Gambar 3.4.1 Pembagian Data Latih dan Data Uji

Selanjutnya, akan dilakukan pelatihan model MLP dengan satu *hidden layer*. Nilai parameter yang digunakan dapat dilihat pada tabel berikut.

Tabel 3.4.1 Nilai Parameter Model


No.	Parameter	Nilai
1	Jumlah <i>Hidden Layer</i>	1
2	Jumlah Neuron pada <i>Hidden Layer</i>	4
3	Fungsi Aktivasi	[ReLU, ReLU]
4	<i>Learning Rate</i>	0.1
5	<i>Epoch</i>	2000

Pada penelitian ini, digunakan *loss function* berupa Mean Squared Error (MSE). Berikut ini grafik perubahan nilai *loss function* selama pelatihan model.



Gambar 3.4.2 Perubahan Nilai MSE Selama Pelatihan Model

Setelah itu, dilakukan prediksi pada data uji. Hasil prediksi dapat dilihat pada grafik di bawah ini.



Gambar 3.4.3 Hasil Prediksi Model

Dari grafik di atas, dapat dilihat bahwa prediksi model MLP sangat dekat dengan data aktual. Melalui proses evaluasi, diperoleh nilai MSE sebesar 1639,024 untuk data latih dan 1885,833 untuk data uji. Dengan mengakarkan nilai MSE, dapat dikatakan bahwa prediksi model rata-rata hanya menyimpang sejauh 40 hingga 44 rupiah dari harga saham penutupan BBRI sebenarnya. Galat yang kecil ini menandai bahwa model tidak mengalami *underfitting*. Selain itu, selisih yang tidak jauh antara MSE latih dan MSE uji menunjukkan bahwa model juga tidak mengalami *overfitting*. Berdasarkan beberapa hal tersebut, dapat disimpulkan bahwa model tersebut cukup baik dalam memprediksi harga penutupan saham BBRI.

4. KESIMPULAN

Dari penelitian yang telah dilakukan, dapat diperoleh kesimpulan sebagai berikut.

- a. Model MLP dapat digunakan untuk memodelkan dan memprediksi harga penutupan saham BBRI dengan akurat
- b. Model MLP dengan satu hidden layer dengan empat neuron, fungsi aktivasi ReLU, *learning rate* sebesar 0.1, dan epoch sebanyak 2000 mampu memprediksi harga penutupan saham BBRI dengan MSE latih sebesar 1639,024 dan MSE uji sebesar 1885,833.